Bu bölümde Apache Spark küüphanesinde bulunan RDD yapısını inceleyeceğiz

RDD(resilient distributed dataset) genel olarak Spark cluster üzerinde veriler üzerinde hesaplamalar yapmamızı sağlayanbir bileşendir.

Aynı zamanda verileri diğer sistemleri aktarabiliriz.

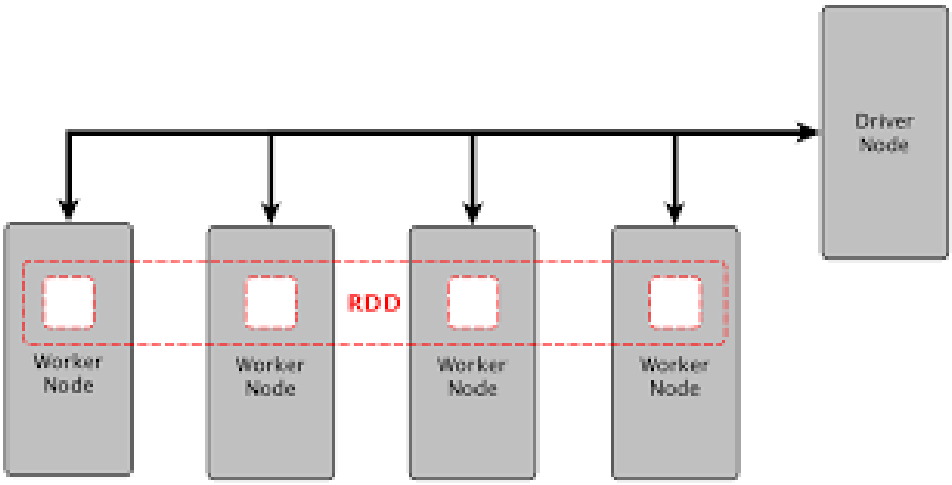

Örnek verirsek alttaki kod yapısı; okuduğumuz dosyanın kaç satır olduğunu cluster üzerinde hesaplar

```
val spark =
SparkSession.builder.master("local").appName("SparkByExample").g
etOrCreate()
val
rdd=spark.sparkContext.textFile("/Users/serkan/Desktop/Training/
sample3.txt");
println("Count : " + rdd.count())
println("Count : " + rdd.first())
```

RDD Nasil Olusturulur

Local bilgisayardan dosya ile

```
val
rdd=spark.sparkContext.textFile("/Users/serkan/Desktop/Training/sample3.txt
");
```

Hdfs uzerinden

```
val rdd=spark.sparkContext.textFile("hdfs://user/file");
```

Zip dosyalari uzerinden

```
val rdd=spark.sparkContext.textFile("/Users/serkan/Desktop/Training/*.gz");
```

parallelize() metodu ile

```
val spark =
SparkSession.builder.master("local").appName("SparkByExample").getOrCreate(
)
val days = List("Sunday", "Monday", "Tuesday", "Wednesday", "Thursday",
"Friday", "Saturday")
val rdd=spark.sparkContext.parallelize(days);
println("Count : " + rdd.count())
println("Count : " + rdd.first())
```

Bu metod genel olarak Spark öğrenmeye başlarken kullanışlı olabilir.Verileri parametre olarak verebiliriz ve bu verilercluster üzerinde dağıtılır

RDD Metodlari

RDD operasyonları genel olarak 2 bölüme ayrılır.

Transformation

Bu işlemde mevcut RDD üzerinden yeni bir RDD oluşturulur.Örnek verirsek map ve filter metodlarından yeni RDD oluşturabiliriz

Alttaki örnekte filter metodu yeni bir RDD oluşturuyor

```
val spark =
SparkSession.builder.master("local").appName("SparkByExample").getOrCreate(
)
val
rdd=spark.sparkContext.textFile("/Users/serkan/Desktop/Training/error.txt")
;
println("Count : " + rdd.count())
println("Count : " + rdd.first())

val filteredRDD =  rdd.filter(line => line.contains("WARN"))

println("----------------------- > Filtered Count : " +
filteredRDD.count())
filteredRDD.foreach(line => println("--------------------------->" + line))
```

Action

Bu işlemde RDD üzerinden hesaplama,dış sistemlere verileri kaydetme işlemleri yapılır. Örnek olarak count,first metodları örnek verilebilir

Alttaki örnekte take metodu ile ilk 2 kayıt List yapısında gösteriliyor . Benzer şekilde collect metodu ise tüm verileri cluster üzerinden toplamaya yarar

```
val spark =
SparkSession.builder.master("local").appName("SparkByExample").getOrC
reate()
val
rdd=spark.sparkContext.textFile("/Users/serkan/Desktop/Training/error
.txt");


val twoRecord = rdd.take(2);

for (line <- twoRecord)
 println("-------> " + line)
```

Lazy Evolution Kavrami

Apache Spark mimarisinde transformasyon işlemlerinde herhangi bir aksiyon alınmaz.Spark count,first,take gibi bir action metodu gördüğü zaman işlemleri başlatır

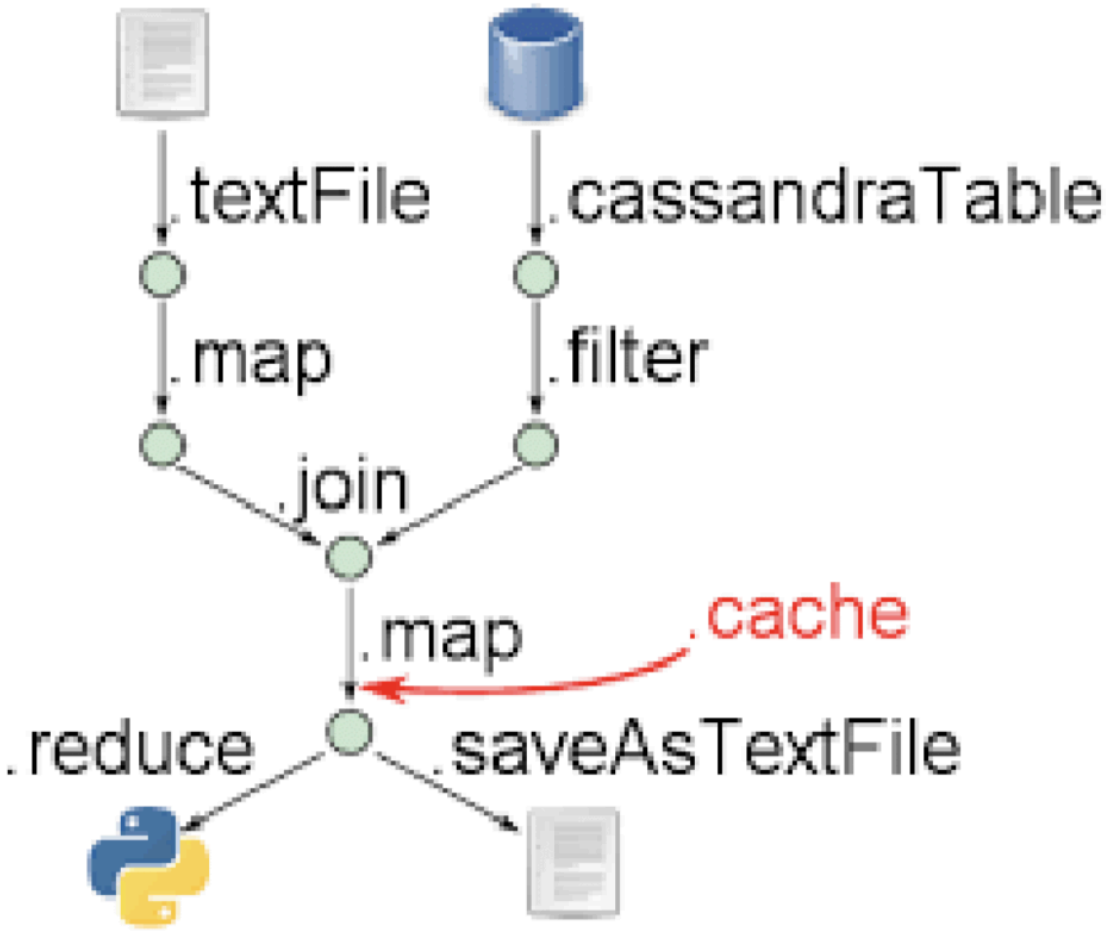
.textFile
.cassandraTable
.map
.filter
.join
.map
.cache
.reduce
.saveAsTextFile